## 1. Знакомство с линейной алгеброй

Ключевыми понятиями линейной алгебры являются «вектор» и «матрица». Для понимания того, каким образом они появляются в анализе данных, можно рассмотреть несколько примеров.

Имеется сеть магазинов, требуется предсказать прибыль для каждого из них в следующем месяце. В данной задаче магазины являются **объектами**, которые необходимо описать с помощью числовых характеристик — **признаков**.

В качестве признаков можно рассмотреть, к примеру, прибыль магазина в предыдущие четыре месяца: 50, 47, 52, 55. Будущая прибыль магазина также зависит от планируемого числа акций для трех основных категорий: кондитерские изделия, овощи и фрукты, мясо. Это следующие три признака: 5, 1, 2. Прибыль зависит и от географического положения магазина, следовательно, его координаты также являются признаками: 55,73, 37,59. Последним рассматриваемым признаком будет количество праздничных дней в следующем месяце: 1.

Все описанные числа в совокупности образуют набор, называемый вектором:

$$\vec{x} = (50, 47, 52, 55, 5, 1, 2, 55, 73, 37, 59, 1).$$

Другим примером является задача определения для каждой конкретной бутылки вина сорта винограда, из которого оно сделано. Это может пригодиться при определении качества вин в зависимости от дороговизны сорта винограда. Здесь признаками являются результаты химических анализов (содержание алкоголя, щелочность, насыщенность цвета). Эти признаки также образуют вектор, на основе которого можно будет делать прогнозы:

$$\vec{x} = (14,23, 1,17, 3,43, 5,64, 3,92).$$

Каждый человек характеризуется своим геномом. Именно геном определяет предрасположенность к некоторым наследственным заболеваниям. Можно поставить следующую задачу: предсказать по геному человека, заболеет ли он раком в течение пяти лет. Это зависит от наличия мутаций в геноме. В связи с этим можно описать каждого конкретного человека вектором, длина которого будет равна количеству возможных мутаций. Данный вектор будет состоять из нулей и единиц, причем единицы будут стоять на позициях, соответствующих произошедшим мутациям:

$$\vec{x} = (0, 1, 0, 0, 1, \dots).$$

Если рассматривается несколько магазинов или несколько бутылок вина, то данные обретают двумерную структуру. Их можно составить в таблицу, в которой строки будут соответствовать объектам, а столбцы — признакам. Такая структура называется матрицей.

#### 2. Векторные пространства

Понятие «вектор» формализуется с помощью *векторных пространстве* — множеств, обладающих определенными свойствами. Тогда **вектор** — это элемент векторного пространства.

**Векторное пространство** — это множество V, на котором заданы две операции: сумма векторов и умножение вектора на число. Эти операции замкнуты — и сумма любых двух векторов, и произведение любого вектора на любое число являются векторами.

Сложение и умножение на число должны удовлетворять следующим аксиомам:

- 1)  $x + y = y + x \ \forall x, y \in V$  (коммутативность);
- 2)  $x + (y + z) = (x + y) + z \ \forall x, y, z \in V;$
- 3)  $\exists 0 \in V : x + 0 = x \ \forall x \in V;$
- 4)  $\forall x \in V \ \exists -x \in V : \ x + (-x) = 0;$
- 5)  $\alpha(\beta x) = (\alpha \beta)x$ ;
- 6)  $1 \cdot x = x$ ;
- 7)  $(\alpha + \beta)x = \alpha x + \beta x;$
- 8)  $\alpha(x+y) = \alpha x + \alpha y$  (дистрибутивность).

Наиболее простые векторные пространства состоят из векторов, каждый элемент которых является вещественным числом. Такие пространства называются **евклидовы** и обозначаются  $\mathbb{R}^n$ , где n — это число элментов в каждом векторе данного пространства. Например,  $\mathbb{R}^2$  — это все точки на плоскости, а  $\mathbb{R}^3$  — все точки в пространстве.

Операции в евклидовом пространстве вводятся поэлементно. Поэлементное сложение выглядит следующим образом:

$$\vec{a} = (a_1, \dots, a_n), \quad \vec{b} = (b_1, \dots, b_n) \quad \Rightarrow \quad \vec{a} + \vec{b} = (a_1 + b_1, \dots, a_n + b_n).$$

Поэлементное умножение на число задается аналогично:

$$\vec{a} = (a_1, \dots, a_n), \quad \beta \in \mathbb{R} \quad \Rightarrow \quad \beta \vec{a} = (\beta a_1, \dots, \beta a_n).$$

В примере с определением сорта винограда векторным пространством являются все возможные признаковые описания бутылок с вином. При этом конкретный вектор — это описание конкретной бутылки. Векторы можно усреднять, например, посчитать среднее признаковое описание для конкретного сорта:

$$\bar{\vec{x}} = \frac{1}{m}(x_1, \dots, x_n).$$

В этой задаче можно провести некоторый анализ данных, например, искать сорт с наибольшим содержанием алкоголя.

## 3. Линейная независимость

Рассматриваются сто магазинов, каждый из которых описывается десятью признаками. Можно составить таблицу  $100 \times 10$ , в которой каждая строка будет соответствовать признаковому описанию одного магазина, а каждый столбец — набору значений одного признака для всех магазинов. В качестве вектора в данном случае будут рассматриваться cmonбusia такой таблицы.

Если, к примеру,  $x_1 = 1000x_2$ , то это может означать, что первый признак является весом товара в граммах, а второй — в килограммах. Это избыточная информация, так как достаточно знать вес в одной из единиц измерения. Значит, можно оставить лишь один вектор из этих двух.

Если также  $x_3 = 0.5x_4 + 0.5x_5$ , то это может означать, что четвертый и пятый признаки являются прибылью магазина в прошлом и позапрошлом месяцах, а третий является средней прибылью за последние два месяца. Здесь снова имеется избыточная информация.

Описанная ситуация носят название *линейная зависимость* (один вектор равен сумме других векторов с коэффициентами). Линейная зависимость ведет к лишним затратам на хранение данных и вредит некоторым методам машинного обучения.

**Определение 1.** Пусть дан набор векторов  $\vec{x}_1, \ldots, \vec{x}_n$ . Они являются **линейно зависимыми**, если существуют такие числа  $\beta_1, \ldots, \beta_n$ . хотя бы одно из которых не равно нулю, что сумма векторов с такими коэффициентами равна нулю:

$$\beta_1 \vec{x}_1 + \dots + \beta_n \vec{x}_n = \vec{0}.$$

Возможно и альтернативное определение линейной зависимости. Векторы **линейно зависимы**, если один из них линейно выражается через остальные:

$$\vec{x}_i = \beta_1 \vec{x}_1 + \dots + \beta_{i-1} \vec{x}_{i-1} + \beta_{i+1} \vec{x}_{i+1} + \dots + \beta_n \vec{x}_n.$$

Данное определение аналогично определению ??.

Необходимо отметить, что если один из векторов нулевой, то все они являются линейно зависимыми: берется коэффициент при нулевом векторе равным 1, при остальных — равным 0, и определение будет выполнено. Это вполне логично, так как нулевой вектор не содержит никакой информации, а вся система становится избыточной.

**Определение 2.** Пусть дан набор векторов  $\vec{x}_1, \dots, \vec{x}_n$ . Они являются **линейно независимыми**, если уравнение:

$$\beta_1 \vec{x}_1 + \dots + \beta_n \vec{x}_n = \vec{0}$$

выполнено только при:

$$\beta_1 = \beta_2 = \dots = \beta_n = 0.$$

Пусть даны три вектора из евклидового пространства  $\mathbb{R}^3$ :

$$\vec{x}_1 = (2, 1, 2), \quad \vec{x}_2 = (4, 2, 4), \quad \vec{x}_3 = (1, 2, 3).$$

Можно заметить, что:

$$2\vec{x}_1 - \vec{x}_2 + 0\vec{x}_3 = \vec{0},$$

следовательно, система этих векторов являются линейно зависимой.

Если же заменить первую координату второго вектора:

$$\vec{x}_1 = (2, 1, 2), \quad \vec{x}_2 = (5, 2, 4), \quad \vec{x}_3 = (1, 2, 3),$$

то система становится линейно независимой. Есть два варианта это понять. Первый вариант — метод  $\Gamma aycca$ , позволяющий привести систему к такому виду, что линейная независимость становится очевидной. Второй вариант является более простым и заключается в  $\varepsilon buucnehuu$  pahra, которое будет изучено далее.

**Определение 3.** Пусть дано некоторое векторное пространство V. Максимальное число линейно независимых векторов в нем называется **размерностью** и обозначается  $\dim V$ .

В евклидовом пространстве  $\mathbb{R}^n$  размерностью является n. Набор векторов, через который выражается любой другой вектор пространства, называется **базисом** векторного пространства:

$$\vec{e}_1 = (1, 0, \dots, 0), \quad \vec{e}_2 = (0, 1, \dots, 0), \quad \dots, \quad \vec{e}_n = (0, 0, \dots, 1).$$

## 4. Операции в векторных пространствах

Рассматривается вектор в двумерном пространстве, выходящий из нуля и идущий в точку (1,2) (см. рис. 1). Длина данного вектора измеряется следующим образом:

$$\sqrt{1^2 + 2^2} = \sqrt{5}.$$

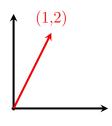
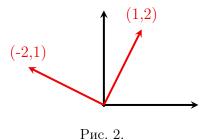


Рис. 1.

K данному вектору добавляется еще один, выходящий из нуля и идущий в точку (-2,1) (см. рис. 2). Угол между этими векторами равен  $90^{\circ}$ .



Расстояние между точками можно найти следующим образом:

$$\sqrt{(1-(-2))^2+(2-1)^2}=\sqrt{10}.$$

Необходимо обобщить эти понятия на многомерное евклидово пространство. Длина вектора обобщается с помощью **нормы** — функции от вектора ( $||\vec{x}||$ ). Норма должна удовлетворять трем требованиям:

- 1) Если  $||\vec{x}|| = 0$ , то  $\vec{x} = 0$ ;
- 2)  $||\vec{x} + \vec{y}|| \le ||\vec{x}|| + ||\vec{y}||$  (неравенство треугольника);
- 3)  $||\alpha \vec{x}|| = |\alpha| \cdot ||\vec{x}||$ .

Векторное пространство, в котором введено понятие «норма», называется *норми- рованным*. Самым распространенным примером нормы является *евклидова норма*:

$$||\vec{x}||_2 = \sqrt{\sum_{i=1}^n x_i^2}.$$

Другим примером является манхэттенская норма:

$$||\vec{x}||_1 = \sum_{i=1}^n |x_i|.$$

Расстояние обобщается с помощью метрики:

$$\rho(\vec{x}, \vec{y}) = ||\vec{x} - \vec{y}||.$$

Метрика соответствует геометрическим представлениям (см. рис. 3).

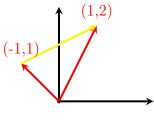


Рис. 3.

Евклидова метрика задается следующим образом:

$$\rho(\vec{x}, \vec{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}.$$

Манхэттенская метрика имеет вид:

$$\rho(\vec{x}, \vec{y}) = \sum_{i=1}^{n} |x_i - y_i|.$$

Пусть имеются два вектора: один с координатами (-1,1) и второй с координатами (1,2). Между ними можно найти расстояние, можно найти их нормы и посчитать угол между ними. Затем оба вектора умножаются на 2. Получены векторы с координатами (-2,2) и (2,4). Изменятся их нормы и расстояние между ними, а угол останется тем же.

Таким образом, необходимо обобщить и понятие «угол», так как нормы и расстояния оказалось недостаточно.

Скалярное произведение двух векторов выглядит следующим образом:

$$\langle \vec{x}, \vec{y} \rangle = \sum_{i=1}^{n} x_i y_i.$$

Через скалярное произведение можно вычислить норму и расстояние:

$$||\vec{x}|| = \sqrt{\langle \vec{x}, \vec{x} \rangle}, \quad \rho(\vec{x}, \vec{y}) = ||\vec{x} - \vec{y}|| = \sqrt{\langle \vec{x} - \vec{y}, \vec{x} - \vec{y} \rangle}.$$

В евклидовых пространствах скалярное произведение можно вычислить с помощью косинуса угла между этими векторами:

$$\langle \vec{x}, \vec{y} \rangle = ||\vec{x}|| \cdot ||\vec{y}|| \cos(\vec{x}, \vec{y}).$$

Отсюда следует, что:

$$\cos(\vec{x}, \vec{y}) = \frac{\langle \vec{x}, \vec{y} \rangle}{||\vec{x}|| \cdot ||\vec{y}||}.$$

Косинус угла, по сути, является мерой сонаправленности векторов, так как для параллельных векторов:

$$\cos(\vec{x}, \vec{y}) = 1,$$

а для перпендикулярных векторов:

$$\cos(\vec{x}, \vec{y}) = 0.$$